

A Hash Table Without Hash Functions 论文综述

1 论文要解决的核心问题

这篇论文研究的问题可以概括为：

对于一个存储 n 个 $(1 + \Theta(1)) \log n$ -bit key/value pairs 的 hash table，它究竟能提供多强的 probabilistic guarantee？

传统上，人们讨论 hash table 的强概率保证时，几乎总是绕不开 hash functions。已知结果表明：

- 如果允许 fully-random hash functions，那么可以把 failure probability 压得很低；
- 但如果要求使用显式、可高效求值的 hash-function families，那么保证往往会退化到

$$\frac{1}{\text{poly}(n)}.$$

因此，这篇论文真正追问的并不只是“哈希表能不能更强”，而是：

hash table 的能力边界，到底是 hash table 本身的边界，还是现有 hash-function paradigm 的边界？

作者给出的回答非常鲜明：很多限制并不是 hash table 这个目标的内在限制，而是“必须通过 hash functions 来实现它”这一范式的限制。

2 论文的核心观点

我认为整篇论文最重要的一句话，其实就是标题本身：

A Hash Table Without Hash Functions.

作者的核心观点是：

- hash table 的本质目标，是实现 randomized dictionary；
- hash functions 只是传统实现路径，而不是逻辑上唯一必要的组成部分；
- 如果直接把随机性嵌入数据结构布局中，而不是交给一个外部 hash function 去分配元素，那么有可能绕开已有 hash-function families 的瓶颈。

这篇论文的真正创新不只是“构造了两个新结构”，而是：

它把“hash table 必须依赖 hash functions”这个默认前提拆掉了。

在我看来，这是这篇论文最有研究味的地方。

3 论文的主要结果

论文给出两条主结果线。

3.1 amplified rotated trie

第一条结果追求极强的 failure probability。

作者在 rotated-trie 路线上进一步构造出 amplified rotated trie，其性质是：

- 线性空间；
- 支持 constant-time operations；
- 使用 $O(n)$ random bits；
- 每次操作失败概率达到

$$O\left(\frac{1}{n^{n^{1-\epsilon}}}\right),$$

其中 $\epsilon > 0$ 是任意正常数。

这比通常意义上的 high probability 强得多，而且作者进一步论证：如果再把 failure probability 显著推进到

$$\frac{1}{n^{\epsilon n}},$$

那么就会逼近 deterministic constant-time dictionary 这个更大的 open question。因此这个结果在某种意义上已经接近理论边界。

3.2 budget rotated trie

第二条结果追求极省的 random bits。

作者构造 budget rotated trie，其性质是：

- 线性空间；
- 支持 constant-time operations with high probability；
- 只使用

$$O(\log n \log \log n)$$

random bits；

- failure probability 为

$$\frac{1}{\text{poly}(n)}.$$

这个结果不是随机位数量上的新纪录：论文指出，Dietzfelbinger、Gil、Matias 和 Pippenger 的工作已经能在当前 key-size setting 下用 $O(\log n)$ random bits 达到同级别概率保证。它的价值主要在于不直接依赖在线 hash-function evaluation 的结构路线、对 gradually-increasing-independence 的初始化阶段使用，以及它后来作为 succinct transformation 的关键组件。

3.3 succinct transformation

在上述两条结果之外，论文还证明了一个更通用的 succinctness 结果：

在 Theorem 7 的前提条件下，符合规定空间形式的 constant-time dictionary，可以被变换成 succinct constant-time dictionary，同时近似保留它的 random-bit usage 与 failure probability。

因此，前面两条主结果都能被推进到 succinct setting 中。这一步把论文从“两个具体构造”提升成了“一个新的通用结构变换框架”。

4 模型边界与结果口径

前面的主要结果需要放在论文规定的模型中理解。首先, Section 2–5 主要讨论至多存储 n 个 $\Theta(\log n)$ -bit key/value pairs 的非 succinct dictionary, 并默认机器字长为 $\Theta(\log n)$; 更大字长的情形放在 Appendix A, 不能直接套用前面的结论。

其次, 论文中的 **failure** 主要不是正确性错误, 而是某次操作耗时超过常数时间。在 succinct dictionary 中, failure 还可能表示结构无法满足规定的空间界。因此, 本文后面所说的“失败概率”应理解为时间或空间保证失败概率, 而不是查询返回错误答案的概率。

论文还采用了几个重要的分析约定: 操作序列独立于随机比特, 即 adversary 是 oblivious 的; 通过周期性 rebuild, 把一个分析阶段限制在 $O(n)$ 次操作内; 概率是针对任意给定操作的 per-operation 概率, 不是整个无限生命周期永不失败的概率; 一旦阶段内发生 failure, 后续操作可以退化为较慢实现。

这些条件意味着论文证明的是一种模型化的概率时间保证, 而不是对任意自适应输入、任意长操作序列和所有随机比特都成立的工程实现承诺。

Theorem 7 也不是对任意 constant-time dictionary 无条件适用。输入需要是论文规定的 $(r(n), p(n), n \log n)$ -dictionary, 且 $r(n)$ 、 $p(n)$ 满足单调性和范围约束, 包括

$$\exp(-n^{1-\epsilon}) \leq p(n) \leq 1/\text{polylog}(n).$$

变换后的随机位和失败概率也不是完全不变, 而是分别增加

$$(\log p(n)^{-1})(\log \log n)^3$$

级别的随机位, 并把失败概率参数变为 $p(n/\log \log n)$ 。

5 相关工作与课程联系

5.1 相关工作的主线

传统 hash table 通过 hash function 把 key 映射到数组位置, universal hashing、perfect hashing、cuckoo hashing 等路线都把冲突控制交给显式随机映射, 再结合重建、多个候选位置或二级结构保证性能。本文并不是否定这些技术, 而是追问: 随机性是否可以直接嵌入数据结构布局, 从而绕开“既要足够强、又要常数时间求值”的 hash-function family 瓶颈。

论文直接依赖或重点对照的工作包括: Fredman–Komlós–Szemerédi 的 perfect hashing; Fredman–Willard 与 Pătraşcu–Thorup 的 fusion/dynamic fusion node; Dietzfelbinger、Gil、Matias 和 Pippenger 的 polynomial hash functions; Raman–Rao 的 succinct dynamic dictionaries; Celis–Reingold–Segev–Wieder 以及 Meka–Reingold–Rothblum–Rothblum

的 load-balancing families; 以及 Pătraşcu–Thorup 关于 simple tabulation hashing 的研究。

这些工作分别提供了空间压缩、局部 deterministic constant-time、少随机位 hashing、succinct reduction、负载均衡和强概率 hashing 等工具。本文的综合性贡献在于把其中一部分工具重新放入 rotated trie 的结构框架中，而不是继续寻找一个统一的完美 hash function。

论文发表后的相关方向应谨慎表述为相邻研究，而不是本文的直接定理级后续。近年的 Modern Hashing Made Simple 继续研究如何用较标准的工具获得强时间和空间保证；Optimal Non-Oblivious Open Addressing 则研究满负载、动态空间和高概率常数时间的 open-addressed table。它们与本文共享重新审视传统 hash-table 约束的问题意识，但技术模型不同，并不等同于对 rotated trie 或 Theorem 7 的直接改进。

5.2 与课程内容的联系

- **Hashing:** 论文直接研究有限随机位、independence、冲突和最大负载，核心问题与课程 Hashing 部分一致。
- **Perfect hashing:** perfect hashing 主要追求给定集合上的无冲突；本文允许极低概率的时间或空间失败，因此目标是概率保证而不是绝对无冲突。
- **Cuckoo hashing:** cuckoo hashing 依靠多个候选位置和重定位控制冲突；rotated trie 则通过 source node 的局部 rotation 和 overlay 控制负载，体现了另一种结构化随机路线。
- **Bloom filter:** Bloom filter 的 false positive 是语义层面的近似错误；本文的 failure 是时间或空间保证失败，不能混为一谈。
- **Succinct structures:** Section 6 通过 trie path 隐式保存 key 的高位，再转成 many-sets，并用 skeleton、storage array 和 backyard 控制空间与失败元素，是本文与 succinct data structures 最直接的连接。

6 整篇论文的技术主线

从正文结构看，这篇论文的技术推进非常整齐，可以概括成下面四步。

6.1 从 classic radix trie 出发

作者没有一开始就提出复杂结构，而是先从经典的 n -ary radix trie 出发。这个结构的优点是：

- 查询路径是确定的；

- 每步只是数组索引；
- 很自然地支持 constant-time operations。

但它的致命问题是空间太差。内部节点可能有 $\Theta(n)$ 个，每个节点又维护大小为 n 的数组，因此总空间可能达到 $\Omega(n^2)$ 。

所以作者的第一个目标不是改进概率保证，而是：

保留 radix trie 的常数时间骨架，同时摆脱其平方级空间浪费。

6.2 把随机性嵌入布局：rotated radix trie

作者给每个 internal node 的数组加入一个随机 rotation，再把所有这些旋转后的数组叠加到一个统一数组中。

这里最关键的思想是：

- 元素不再通过 hash function 被送进桶；
- 而是通过数据结构内部的随机 rotation 被打散并叠加。

统一数组中的每个位置由 dynamic fusion node 承载，只要每个位置的负载不超过 $\text{polylog}(n)$ ，结构就仍然可以常数时间操作。

这一节最大的意义不在于最终结论本身，而在于它第一次证明：

一个像 hash table 一样工作的 randomized dictionary，并不一定要借助传统 hash functions 才能存在。

6.3 amplified 路线：增加随机源数量，压低 failure probability

Section 4 的核心观察是：Section 3 还不够强，不是因为分析工具不够，而是因为决定结构的随机源太少，导致依赖太强。

作者的修正是：

- 把 fanout 从 n 降到 n^δ ；
- 这样每个 internal node 最多只承载 n^δ 个 balls；
- 从而强制 internal nodes 的数量至少达到 $n^{1-\delta}$ 。

这一步相当于把随机性分散到更多局部结构中，然后作者不再逐个 bin 地分析，而是直接分析 overflow balls 总数 q ，并用 McDiarmid' s inequality 证明：

$$\Pr[q \geq n^{1-\delta}]$$

极小，从而得到接近极限的 failure probability。

所以 amplified 路线的关键不是“更强的哈希”，而是：

通过改变 trie 的结构参数，让全局随机变量变得足够可集中。

6.4 budget 路线：拆分随机性层级，压低 random bits

Section 5 则换了一个方向。作者不再试图压到极低 failure probability，而是尽量减少 random bits 的使用。

这里最精彩的设计，是把 balls-to-bins mapping 拆成两层：

- a_s 控制 ball 被送到哪个 group；
- b_s 控制它在 group 内落到哪个 bin。

于是两层问题可以分别用两种不同强度的随机工具：

- 用 $O(1)$ -independent hash functions 控制 group-level balancing；
- 用 gradually-increasing-independence hash functions 控制 within-group balancing。

更妙的是，作者没有把后者当作在线 hash function，而是只把它当成 internal node 初始化时的一次性 pseudo-random number generator。这样就绕开了它求值慢的缺点。

这说明作者的方法论很明确：

不要执着于找一个“完美 hash function”一次性解决所有问题，而要先把随机性需求按结构层次拆开，再把不同工具放到最合适的时机与位置。

6.5 succinct 路线：reduction + many-sets + backyard

Section 6 的技术味道与前面不同。这里作者没有再直接发明一个新的 hash-table-like structure，而是先做一个 Raman-Rao reduction，把 succinct dictionary 问题转成 many-sets problem。

然后通过：

- skeleton + storage array
- budget rotated trie
- backyard dictionary

来解决 many-sets problem。

这条路线的关键思想是：

1. 利用 trie path 隐式编码高位 bits，从而“剃掉”每个元素需要显式存的 key bits；
2. 对大量小 skeleton 共享 random bits，而不是每个都独立抽样；

3. 允许局部 skeleton 偶尔失败，但把失败元素统一收容到一个规模可控的 backyard 中。

因此 succinctness 在这篇论文里不是局部压缩技巧，而是：

通过问题重表示、失败元素隔离、以及随机位共享来实现的全局结构变换。

7 我对论文贡献的理解

我认为这篇论文至少有三层贡献。

7.1 概念层贡献

它挑战了一个长期默认前提：

实现 hash table，似乎就应该先找 hash function family。

论文表明，这个前提并不必要。你可以直接设计 randomized dictionary structure，把随机性塞进布局本身，而不是交给哈希函数来调度。

7.2 技术层贡献

作者并没有停留在概念突破上，而是沿着同一条 rotated-trie 路线做出了两端都很强的结果：

- 一端是几乎极限的 failure probability；
- 另一端是几乎极省的 random bits。

这说明 rotated-trie 不是一次性的技巧，而是一条可扩展的技术路线。

7.3 框架层贡献

Section 6 的通用 transformation 让论文的价值超出了“发明两个结构”本身。它表明前面的结果不是孤立的，而是可以被系统地推进到 succinct setting。

这一点很重要，因为很多论文只能在“普通线性空间版本”里做出结果，而这篇论文进一步说明：

绕开 hash-function bottleneck 的新路线，并不与 succinctness 冲突。

8 我认为这篇论文最精彩的地方

对我来说，这篇论文最精彩的地方有三处。

8.1 问题设定很准

作者没有直接硬攻 deterministic constant-time dictionary，而是把它自然放宽为：

最小 failure probability 能做到多少？

这个问题既保留了理论强度，又给了随机化结构发挥空间。

8.2 “不用 hash functions” 不是口号，而是可落地的结构路线

很多标题型想法听起来有噱头，但正文未必真正摆脱旧框架。这篇论文不是这样。rotated trie、amplified trie、budget trie 这几层结构都确实把随机性嵌进了数据结构内部，而不是换个名字继续做 hashing。

8.3 对 random bits 的使用非常讲究

这篇论文不是把随机性当无限资源，而是一直在问：

- 若 random bits 多，能换来多强的 failure guarantee？
- 若 random bits 少，能否仍做出好结构？
- 不同位置所需的随机性强度是否不同？

标题里的

How to Get the Most Out of Your Random Bits

在正文里是有实质内容支撑的。

9 我觉得较难但值得反复看的部分

如果从阅读体验上看，我觉得以下几部分最值得反复回读。

9.1 Section 3 到 Section 4 的过渡

这里的关键不是定理本身，而是作者如何从“某些 bin 负载可控”转向“overflow 总量可控”，以及为什么 McDiarmid 比逐 bin Chernoff 更适合这一层分析。

9.2 Section 5 对 slowly-evaluable hash functions 的重新安置

这部分很有启发性。作者不是否认这类 hash functions 的价值，而是把它们从在线查询路径中移走，只放到 internal node 初始化阶段。

这给我的启发是：

一个工具是否“适合数据结构”，往往不只取决于它本身，还取决于你把它放在数据结构生命周期的哪个阶段。

9.3 Section 6 的 backyard 设计

这里最核心的不是具体界，而是这种思路：

接受局部失败，但必须把失败限制成一个全局上很薄、空间上可吸收的异常层。

这是一种很强的结构设计观念。

10 我对论文局限或开放问题的理解

虽然这篇论文很强，但我觉得它也自然留下了一些后续问题。

10.1 大 universe 情形仍然更复杂

正文主结果主要围绕 $\Theta(\log n)$ -bit keys/values 展开。附录里作者讨论了 super-polynomial universe 的处理方式，但整体路线已经更依赖额外的 universe reduction 技术。

这说明：

“不用 hash functions”的主路线，在更大 word-size setting 下仍然会面对新的障碍。

10.2 结构比较复杂，工程可实现性未必直观

从理论角度看，rotated trie 路线非常漂亮；但若站在系统实现角度，它涉及：

- dynamic fusion nodes;
- 多层随机布局;
- backyard;
- succinct transformation;

这些成分叠加后，工程实现难度显然不低。也就是说，这篇论文的价值首先是理论突破，而不是短期内可直接替换工业 hash table 的方案。

10.3 deterministic constant-time dictionary 仍然悬而未决

作者其实是在不断靠近这个更大的 open question，但并没有真正解决它。恰恰因为这篇论文把 randomized 边界推进得更靠前，反而让这个大问题显得更尖锐了。

11 我的总体评价

总体上，我认为这是一篇非常有代表性的理论数据结构论文，原因在于它同时满足几件事：

- 问题设定准确，而且与长期 open question 有自然联系；
- 核心观点鲜明，不是局部修补而是范式绕行；
- 技术推进有连续主线，不是若干彼此无关的小技巧拼接；
- 结果既有强数值界，也有通用 transformation；
- 标题中的研究承诺，在正文里被真正兑现了。

如果只用一句话概括我对这篇论文的看法，我会写成：

这篇论文最厉害的地方，不只是把 failure probability 做得更低、把 random bits 用得更省，而是证明了“hash table 的强概率保证”并不必然受困于传统 hash-function paradigm。

12 简短结论

这篇论文给我的最大收获，不是某一个定理的尾界，而是一种更一般的认识：

当一个经典数据结构问题长期被某种实现范式所束缚时，真正的突破可能不是继续在旧范式里打磨工具，而是重新思考：这个问题的本质目标到底是什么，哪些组件只是历史上常用、却并非逻辑上必要。

在这个意义上，A Hash Table Without Hash Functions 不只是关于 hash table 的论文，也是一篇很典型的“通过重述问题来获得新结构”的理论数据结构论文。

13 参考文献与调研边界

正文中的相关工作以原论文参考文献为主，重点包括 FKS perfect hashing、fusion trees 和 dynamic fusion nodes、Dietzfelbinger 等人的 polynomial hash functions、Raman–Rao succinct dictionaries、Celis 等人与 Meka 等人的 load-balancing families，以及 Pătraşcu–Thorup 的 simple tabulation hashing。论文发表后的相邻方向只作为背景补充，不把它们宣称为本文的直接延伸：

- William Kuszmaul, *A Hash Table Without Hash Functions, and How to Get the Most Out of Your Random Bits*, FOCS 2022。
- Rajeev Raman and Satti Srinivasa Rao, *Succinct Dynamic Dictionaries and Trees*, 2003。
- Mihai Pătraşcu and Mikkel Thorup, *The Power of Simple Tabulation Hashing*, 2012。
- L. Elisa Celis, Omer Reingold, Gil Segev, and Udi Wieder, *Balls and Bins: Smaller Hash Families and Faster Evaluation*, 2011; Raghu Meka et al., *Fast Pseudorandomness for Independence and Load Balancing*, 2014。
- Michael A. Bender, Martín Farach-Colton, John Kuszmaul, and William Kuszmaul, *Modern Hashing Made Simple*, 作为相邻的现代 hashing 方向。
- Michael A. Bender, William Kuszmaul, and Renfei Zhou, *Optimal Non-Oblivious Open Addressing*, 作为相邻的 open-addressing 方向。